

Análise de Modelos de Regressão Linear Aplicados a Dados de Arsênio e Radiação

08/09/2026

Sumário:

1. Introdução:	3
2. Fundamentação teórica:	3
2.1 Regressão Linear Simples	3
2.2 Regressão Linear Múltipla	4
2.3 Métricas de avaliação:	4
R2:	4
RMSE:	5
MAE	5
3. Protocolo experimental:	5
3.1 Fontes dos dados:	5
3.2 Variáveis utilizadas:	6
3.3 Ferramentas utilizadas:	6
3.4 Procedimento para ajuste dos modelos:	7
4. Resultados e Discussão:	7
4.1 Problema 1:	7
4.2 Problema 2:	8
5. Conclusão:	9

1. Introdução:

A regressão linear é uma técnica usada para analisar a relação entre variáveis e fazer previsões com base em dados. Neste trabalho, ela é aplicada em dois problemas diferentes.

No primeiro, o objetivo é estimar a concentração de arsênio nas unhas de indivíduos, levando em conta fatores como idade, uso da água para beber e cozinhar e a quantidade de arsênio presente na água.

No segundo problema, a regressão é usada para prever a dose de radiação recebida em inspeções por raios X, considerando a corrente elétrica do equipamento e o tempo de exposição.

Também são analisadas algumas outras métricas como R², R² ajustado, MSE, RMSE e MAE para verificar qual modelo apresenta os melhores resultados.

2. Fundamentação teórica:

2.1 Regressão Linear Simples

A regressão linear simples é um método utilizado para representar a relação entre uma variável dependente e uma única variável independente.

Fórmula:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Em que:

- **y** representa a variável dependente;
- **x** representa a variável independente;
- **β_0** representa o intercepto;
- **β_1** representa o coeficiente associado à variável independente;
- **ε** representa o erro ou resíduo do modelo.

2.2 Regressão Linear Múltipla

A regressão linear múltipla é um método utilizado para representar a relação entre uma variável dependente e duas ou mais variáveis independentes.

Fórmula:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

Em que:

- **y representa a variável dependente;**
- **$x_1, x_2, \dots, x_n$ representam as variáveis independentes;**
- **β_0 representa o intercepto;**
- **$\beta_1, \beta_2, \dots, \beta_n$ representam os coeficientes associados a cada variável independente;**
- **ε representa o erro ou resíduo do modelo.**

2.3 Métricas de avaliação:

R²:

O R² (coeficiente de determinação) indica a proporção da variação da variável dependente que é explicada pelo modelo. Seu valor geralmente varia entre 0 e 1, sendo que valores mais próximos de 1 indicam maior capacidade de explicação dos dados.

$$R^2 = 1 - [\Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2]$$

R² Ajustado:

O R² ajustado é uma medida semelhante ao R², porém considera a quantidade de variáveis independentes utilizadas no modelo. Dessa forma, ele aplica uma penalização quando novas variáveis são adicionadas sem proporcionar uma melhora suficiente no ajuste.

MSE:

O MSE (Mean Squared Error) representa o erro quadrático médio entre os valores observados e os valores previstos pelo modelo. Como os erros são elevados ao quadrado, erros maiores possuem maior influência no resultado.

$$\text{MSE} = 1/n \sum (y_i - \hat{y}_i)^2$$

RMSE:

O RMSE (Root Mean Squared Error) corresponde à raiz quadrada do MSE e representa uma medida da magnitude média dos erros de previsão, mantendo a mesma unidade da variável dependente.

$$\text{RMSE} = \sqrt{1/n \sum (y_i - \hat{y}_i)^2}$$

MAE:

O MAE (Mean Absolute Error) representa o erro absoluto médio entre os valores observados e previstos.

$$\text{MAE} = 1/n \sum |y_i - \hat{y}_i|$$

3. Protocolo experimental:

3.1 Fontes dos dados:

- **DATASET 1: arsenio_dataset(1).csv**

Contém 21 participantes e são coletadas informações para conseguir verificar a concentração de arsênio na água e concentração de arsênio nas unhas dos pés.

- **DATASET 2: dose_radiacao_expandido.csv**

540 observações relacionadas à dose de radiação, corrente elétrica e tempo de exposição.

3.2 Variáveis utilizadas:

Problema 1 ->

A variável dependente utilizada foi a concentração de arsênio nas unhas dos pés (ppm).

Variáveis independentes: idade, uso da água para beber, uso da água para cozinhar e arsênio na água.

A variável sexo foi listada mas não foi usada pois não foi solicitada no enunciado da questão.

Problema 2 ->

A variável dependente foi a dose de radiação, em RAD.

Variáveis independentes: corrente, tempo de exposição.

Foi também desenvolvido outro modelo usando apenas a corrente como variável independente.

3.3 Ferramentas utilizadas:

- Python
- Numpy
- Matplotlib
- Arquivos csv

Os parâmetros foram obtidos por meio da solução das matrizes dos mínimos quadrados:

$$\beta = (X^T X)^{-1} X^T y$$

Na implementação foi utilizada a pseudo inversa matricial por meio da função:

$$\text{pinv}(X.T @ X) @ X.T @ y$$

3.4 Procedimento para ajuste dos modelos:

Primeiro foram carregados e organizados os dados dos dois problemas. Depois, foram escolhidas as variáveis que seriam usadas nos modelos e montada a matriz de entrada, com o intercepto quando necessário.

Os coeficientes foram calculados usando o método dos mínimos quadrados e a pseudoinversa. Depois disso, foram feitas as previsões e calculados os resíduos para verificar os erros.

Por fim, os modelos foram avaliados usando R^2 , R^2 ajustado, MSE, RMSE e MAE. Também foram comparados os modelos completos com os mais simples e os modelos com e sem intercepto, para saber qual apresentava os melhores resultados.

A análise dos resíduos também foi utilizada como forma complementar de avaliação do ajuste, por meio da comparação entre os resíduos e os valores ajustados.

4. Resultados e Discussão:

4.1 Problema 1:

Foi utilizado um modelo de regressão linear múltipla para estimar a concentração de arsênio nas unhas dos pés a partir da idade, uso da água para beber, uso da água para cozinhar e concentração de arsênio na água.

O modelo apresentou R^2 de 0,8119 e R^2 ajustado de 0,7649, com MSE de aproximadamente 0,0424, RMSE de 0,2060 e MAE de 0,1156.

O valor de MSE indica que o erro quadrático médio das previsões foi aproximado 0,0424 ppm². Já o RMSE de 0,2060 ppm representa a magnitude dos erros de previsão na mesma unidade da variável dependente.

Para o cenário proposto, com idade de 30 anos, uso da água para beber e cozinhar igual a 5 e concentração de arsênio na água de 0,135 ppm, a previsão obtida foi de aproximadamente 1,9306 ppm.

Também foi testado um modelo utilizando apenas a concentração de arsênio na água como variável independente. Esse modelo apresentou R^2 ajustado de 0,7932, superior ao valor de 0,7649 que foi obtido no modelo completo.

Logo, para esse conjunto de dados, o modelo utilizando apenas a concentração de arsênio na água apresentou maior capacidade de explicação ajustada, apesar de utilizar somente uma variável independente. Esse resultado não significa que a concentração de arsênio na água seja necessariamente um fator causal ou o principal fator do fenômeno, mas indica que, isoladamente e segundo o R^2 ajustado, essa variável apresentou melhor desempenho para explicar a variação observada nos dados.

Também foi avaliado um modelo sem intercepto, onde seu RMSE foi de 0,2142, superior ao RMSE de 0,2060 do modelo com intercepto.

O MSE correspondente ao modelo sem intercepto é de aproximadamente 0,0459, também superior ao MSE de aproximadamente 0,0424 do modelo com intercepto.

Assim, considerando essas métricas, o modelo com intercepto apresentou um ajuste ligeiramente melhor para os dados analisados.

A análise dos resíduos foi realizada por meio do gráfico de resíduos em função dos valores ajustados. Essa análise é importante para verificar se existem padrões nos erros que possam indicar problemas no ajuste do modelo. O gráfico deve ser interpretado conjuntamente com as métricas numéricas, pois um bom valor de R^2 não garante, sozinho, que os resíduos apresentem um comportamento adequado.

4.2 Problema 2:

No segundo problema, o modelo foi ajustado para prever a dose de radiação em função da corrente elétrica e do tempo de exposição.

Utilizando o modelo para prever a dose em uma situação com 15 miliamperes de corrente e 5 minutos de exposição, o resultado obtido foi de 182,6337 rad.

As métricas desse modelo resultaram em R^2 de 0,8430 e R^2 ajustado de 0,8425. O MSE foi de aproximadamente 54.530,05 rad², enquanto o RMSE foi de 233,5167 rad e o MAE foi de 187,5942 rad.

O MSE elevado está relacionado à própria escala dos valores de dose de radiação e, por ser uma métrica baseada no quadrado dos erros, apresenta unidade ao quadrado. Por isso, para interpretar a magnitude dos erros de forma mais direta, o RMSE e o MAE também são considerados.

Comparando o modelo completo, que utiliza corrente e tempo de exposição, com o modelo que utiliza apenas a corrente, o modelo completo apresentou desempenho significativamente superior.

O modelo utilizando somente a corrente apresentou R^2 de apenas 0,0806, enquanto seu RMSE foi de 565,2391 rad, correspondente a um MSE de aproximadamente 319.495,24 rad².

Em comparação, o modelo completo apresentou R^2 de 0,8430 e RMSE de 233,5167 rad. Dessa forma, a inclusão do tempo de exposição proporcionou uma melhora significativa na capacidade do modelo de explicar e prever a dose de radiação para esse conjunto de dados.

Ao forçar o intercepto a zero neste cenário, existe uma justificativa física para essa configuração: se não houver corrente elétrica e não houver tempo de exposição, espera-se que a dose de radiação seja zero.

Entretanto, uma justificativa física para a ausência do intercepto não significa necessariamente que o modelo restrito apresentará melhor ajuste estatístico aos dados observados. Neste caso, isso pode ser verificado pelos resultados obtidos.

O modelo sem intercepto apresentou R^2 de 0,7631 e RMSE de 286,9185 rad, superior ao RMSE de 233,5167 rad do modelo com intercepto. O MSE correspondente foi de aproximadamente 82.322,23 rad².

Portanto, apesar de a restrição do intercepto possuir uma interpretação física coerente, o modelo com intercepto apresentou melhor desempenho estatístico para os dados analisados.

5. Conclusão:

O trabalho mostrou a implementação de modelos de regressão linear por meio de operações matriciais e a utilização de diferentes métricas para avaliar seu desempenho.

No primeiro problema com objetivo de calcular a concentração de arsênio nas unhas dos pés, o modelo de regressão linear múltipla apresentou R^2 de 0,8119 e R^2 ajustado de 0,7649, enquanto que o outro modelo que estava utilizando somente a concentração de arsênio na água apresentou R^2 ajustado de 0,7932. Logo, o modelo mais simples apresentou melhor desempenho segundo o R^2 ajustado para esse conjunto de dados.

Esse resultado indica que a concentração de arsênio na água foi a variável que apresentou maior capacidade de explicação ajustada da variação observada, não sendo possível afirmar apenas com esses resultados que ela seja o principal fator causal do fenômeno.

No segundo problema, relacionado à dose de radiação, o modelo de regressão linear múltipla utilizando corrente elétrica e tempo de exposição apresentou desempenho superior ao que utilizou apenas a corrente. O modelo completo apresentou R^2 de 0,8430, enquanto o modelo somente com a corrente apresentou R^2 de 0,0806. A diferença também foi observada no RMSE, que foi de 233,5167 rad no modelo completo contra 565,2391 rad no modelo com apenas uma variável.

Nesse caso, os resultados indicam que a inclusão do tempo de exposição foi fundamental para melhorar a capacidade de explicação e previsão do modelo.

A comparação entre os modelos com e sem intercepto também mostrou que uma configuração fisicamente plausível não necessariamente apresenta o melhor ajuste. No problema 2, embora o modelo sem intercepto possua uma interpretação física coerente, o modelo com intercepto apresentou menores erros e melhor desempenho nas métricas analisadas.

Dessa forma, os dois problemas demonstraram a importância de avaliar não apenas a quantidade de variáveis utilizadas, mas também o quanto cada uma contribui efetivamente para a qualidade do modelo. A utilização conjunta das métricas, juntamente com a análise dos resíduos, permite realizar uma avaliação mais completa dos modelos e identificar adequadamente cada conjunto de dados.